

Classificação de Tecidos Metastáticos em Imagens Histopatológicas com Transfer Learning e ResNet18

1st Andrey de Oliveira Sabino
Universidade Federal Rural do Semi-Árido (UFERSA)
Pau dos Ferros, RN, Brasil
andrey.sabino@alunos.ufersa.edu.br

2nd João Felype Feitosa Rego
Universidade Federal Rural do Semi-Árido (UFERSA)
Pau dos Ferros, RN, Brasil
joao.rego56478@alunos.ufersa.edu.br

3rd Nathan Cardoso Linhares
Universidade Federal Rural do Semi-Árido (UFERSA)
Pau dos Ferros, RN, Brasil
nathan.linhares@alunos.ufersa.edu.br

4th Pedro Vinicius de Andrade Queiroz
Universidade Federal Rural do Semi-Árido (UFERSA)
Pau dos Ferros, RN, Brasil
pedro.queiroz@alunos.ufersa.edu.br

Resumo—Early detection of metastases plays a fundamental role in cancer diagnosis and treatment and is traditionally performed through the analysis of histopathological images by specialists. However, this process can be time-consuming and subject to human variability. In this context, Artificial Intelligence techniques, especially Convolutional Neural Networks (CNNs), have emerged as promising tools for medical diagnosis support. This work proposes a Transfer Learning approach using a pre-trained ResNet18 architecture as a feature extractor combined with a fully connected neural network for the classification of histopathological images from the PatchCamelyon (PCam) dataset. The model was trained and evaluated using a balanced sample of 18,000 images. The results achieved an accuracy of 82.33%, precision of 88.25%, sensitivity of 74.60%, specificity of 90.07%, F1-score of 80.85%, and an area under the ROC curve (AUC) of 0.9062, demonstrating high discriminative capability between healthy and metastatic tissues.

Index Terms—Metastasis detection, Histopathological images, Transfer Learning, ResNet18.

I. INTRODUÇÃO

O crescimento acelerado das tecnologias digitais tem contribuído para a geração e armazenamento de volumes cada vez maiores de dados, fenômeno conhecido como Big Data. Em diversas áreas do conhecimento, esses dados representam uma importante fonte de informações, permitindo a descoberta de padrões e a obtenção de conhecimento útil para a tomada de decisões. Entretanto, a grande quantidade de informações disponíveis torna necessária a utilização de técnicas capazes de processar esses dados de forma eficiente e automatizada [1].

Na área da saúde, uma das aplicações mais relevantes da análise de dados está relacionada ao diagnóstico de doenças. Entre elas, destaca-se o câncer, cuja progressão pode resultar no surgimento de metástases, processo caracterizado pela disseminação de células tumorais para outras regiões do organismo. A identificação precoce dessas alterações é fundamental para aumentar as chances de sucesso dos tratamentos e reduzir os impactos da doença sobre os pacientes.

Tradicionalmente, a análise de tecidos biológicos e a identificação de sinais metastáticos são realizadas por especialistas

por meio da observação de imagens histopatológicas. Embora esse procedimento apresente elevada confiabilidade, ele pode demandar tempo considerável e estar sujeito à variabilidade inerente à avaliação humana, especialmente quando há grandes quantidades de exames a serem analisados [2].

Nesse contexto, a Inteligência Artificial (IA) tem se consolidado como uma importante ferramenta de apoio ao diagnóstico médico. Técnicas de aprendizado de máquina permitem o desenvolvimento de sistemas capazes de reconhecer padrões complexos em grandes conjuntos de dados, aprendendo características relevantes a partir de exemplos previamente analisados por especialistas [1].

Entre as abordagens mais utilizadas para análise de imagens destacam-se as Redes Neurais Convolucionais (CNNs), que apresentam excelente desempenho na identificação automática de características visuais. Essas redes são capazes de extrair informações diretamente das imagens, reconhecendo padrões relacionados à textura, forma e organização dos tecidos, o que as torna particularmente adequadas para aplicações em diagnóstico médico [1].

Diante desse cenário, torna-se cada vez mais importante investigar e aperfeiçoar modelos computacionais capazes de auxiliar profissionais da saúde na detecção de tecidos comprometidos por processos metastáticos. Além de contribuir para a redução do tempo de análise, tais ferramentas podem aumentar a precisão diagnóstica e fornecer suporte à tomada de decisão clínica [2].

Dessa forma, este trabalho tem como objetivo desenvolver e avaliar um modelo baseado em redes neurais para a identificação de tecidos com sinais de metástase por meio da análise de imagens, buscando contribuir para diagnósticos mais rápidos, precisos e eficientes.

II. FUNDAMENTAÇÃO TEÓRICA

As metástases constituem uma das principais características associadas à progressão do câncer e são responsáveis por grande parte das complicações relacionadas à doença. O processo metastático envolve a disseminação de células tumorais

do sítio primário para outras regiões do organismo, ocorrendo por meio de uma sequência de etapas que incluem invasão tecidual, intravasação, circulação, adesão e proliferação em novos tecidos [3].

Segundo [3], embora milhões de células tumorais possam ser liberadas na circulação, apenas uma pequena fração delas consegue estabelecer uma nova lesão metastática. Esse fenômeno ocorre devido à complexidade biológica envolvida no processo, que depende de fatores como angiogênese, capacidade invasiva, sobrevivência à circulação sanguínea, evasão da resposta imunológica e adaptação ao novo ambiente tecidual.

Os mesmos autores destacam que a formação de metástases não ocorre de maneira aleatória. O sucesso da colonização de um novo tecido depende tanto das características das células tumorais quanto das condições oferecidas pelo ambiente receptor. Essa relação é descrita pela teoria da “semente e solo”, proposta por Paget, segundo a qual determinadas células malignas apresentam maior probabilidade de se desenvolver em tecidos específicos que favorecem sua sobrevivência e proliferação [3].

A identificação dessas alterações geralmente é realizada por meio da análise histopatológica de tecidos. Em estudos envolvendo metástases linfonodais decorrentes do câncer de mama, [4] observaram características como hiperchromasia, pleomorfismo nuclear, desorganização estrutural, necrose e fibrose estromal em amostras com comprometimento metastático. Tais evidências auxiliam na diferenciação entre tecidos saudáveis e tecidos acometidos por células malignas, sendo fundamentais para a avaliação prognóstica e terapêutica.

Devido à complexidade desses padrões morfológicos, métodos computacionais baseados em Inteligência Artificial têm sido amplamente explorados para auxiliar a análise de imagens médicas. Nesse contexto, as Redes Neurais Convolucionais (CNNs) destacam-se por sua capacidade de aprender automaticamente características relevantes a partir dos pixels das imagens, dispensando etapas manuais de extração de atributos [5].

De acordo com [6], as CNNs conseguem identificar variações sutis relacionadas à textura, coloração e estrutura celular, características frequentemente associadas à presença de alterações patológicas. Além disso, esses modelos apresentam elevada robustez diante de grandes volumes de dados e da variabilidade encontrada em lâminas histológicas digitalizadas, tornando-se uma alternativa promissora para aplicações voltadas à detecção de tecidos metastáticos.

Dessa forma, a combinação entre conhecimentos da patologia e técnicas modernas de aprendizado profundo tem possibilitado avanços significativos no desenvolvimento de sistemas capazes de apoiar profissionais da saúde na identificação precoce de metástases e na realização de diagnósticos mais precisos.

O aprendizado por transferência (*Transfer Learning*) tem sido amplamente empregado em aplicações de visão computacional e diagnóstico médico devido à capacidade de reutilizar conhecimentos previamente adquiridos em grandes bases de imagens. Segundo Soares [7], essa abordagem permite reduzir

o custo computacional do treinamento e adaptar modelos pré-treinados para tarefas específicas com quantidades limitadas de dados.

Além disso, o congelamento das camadas convolucionais preserva características visuais previamente aprendidas, tornando o treinamento mais eficiente e reduzindo os riscos de sobreajuste.

A utilização de redes neurais convolucionais em aplicações médicas tem demonstrado potencial para reduzir a subjetividade inerente à análise humana e auxiliar especialistas na tomada de decisão clínica. Matias [8] destaca que sistemas baseados em aprendizado profundo podem atuar como ferramentas de apoio ao diagnóstico, contribuindo para análises mais consistentes e eficientes.

Nesse contexto, a utilização da ResNet18 como extratora de características mostra-se adequada para a identificação de padrões histopatológicos associados a presença de metástases, permitindo o desenvolvimento de modelos computacionais de apoio ao diagnóstico.

III. METODOLOGIA

Este trabalho utiliza técnicas de aprendizado profundo para a detecção automática de metástases em imagens histopatológicas. O conjunto de dados empregado foi o PatchCamelyon (PCam), amplamente utilizado em pesquisas de classificação de tecidos metastáticos. O dataset contém imagens coloridas de tecido linfonodal previamente rotuladas por especialistas, indicando a presença ou ausência de células metastáticas.

Para reduzir o custo computacional e garantir o balanceamento das classes, foi realizada uma amostragem estratificada contendo 18.000 imagens, distribuídas igualmente entre as classes positiva (metástase) e negativa (tecido saudável). O conjunto foi dividido em 12.000 imagens para treinamento, 3.000 para validação e 3.000 para teste, mantendo a proporção de 50% para cada classe em todos os subconjuntos.

As imagens originais possuem resolução de 96×96 pixels. Inicialmente, foi realizado o carregamento das imagens e a conversão para o formato RGB. Em seguida, os valores dos pixels foram normalizados para o intervalo $[0, 1]$. Como a arquitetura utilizada requer imagens de entrada com resolução de 224×224 pixels, foi aplicado um redimensionamento utilizando interpolação bilinear.

O modelo adotado foi a ResNet18 pré-treinada na base ImageNet. Em vez de realizar o treinamento completo da rede, foi empregada a técnica de *transfer learning*. Para isso, a camada classificadora original da ResNet18 foi removida e substituída por uma camada de identidade, permitindo que a rede atuasse exclusivamente como extratora de características.

A escolha da ResNet18 deve-se ao seu reduzido custo computacional e à presença de conexões residuais, que facilitam o treinamento de redes profundas e reduzem problemas relacionados ao desaparecimento do gradiente. Além disso, a utilização de pesos previamente treinados na base ImageNet permite a extração de características relevantes mesmo em conjuntos de dados menores, tornando a abordagem adequada para aplicações médicas [5], [7].




Figura 1: Arquitetura proposta: a ResNet18 pré-treinada e congelada atua como extratora de características, gerando um vetor de 512 atributos que alimenta uma rede neural totalmente conectada responsável pela classificação binária.

Todos os parâmetros da ResNet18 foram congelados, impedindo a atualização dos pesos durante o treinamento. Dessa forma, cada imagem foi convertida em um vetor de características com 512 atributos, representando informações extraídas automaticamente pela rede convolucional.

O congelamento das camadas convolucionais permite preservar os atributos visuais aprendidos durante o pré-treinamento, reduzindo o número de parâmetros ajustáveis e diminuindo o custo computacional do treinamento [7].

Sobre esses vetores foi treinada uma rede neural totalmente conectada composta por três camadas lineares. A arquitetura utilizada foi formada por uma camada de entrada com 512 neurônios, seguida por camadas ocultas de 256 e 64 neurônios, respectivamente. Entre as camadas foram utilizadas operações de normalização em lote (*Batch Normalization*), funções de ativação ReLU e técnicas de regularização por *Dropout* com taxas de 0,5 e 0,3.

Para o treinamento da rede classificadora foi utilizada a função de perda Binary Cross Entropy with Logits (*BCEWithLogitsLoss*), adequada para problemas de classificação binária. A otimização foi realizada por meio do algoritmo Adam, utilizando taxa de aprendizado de 10^{-3} e regularização L2 (*weight decay*) de 10^{-4} .

O treinamento foi executado por até 120 épocas, sendo aplicado o mecanismo de *Early Stopping*. O critério de parada foi baseado na métrica AUC obtida no conjunto de validação. Caso não houvesse melhoria após 12 épocas consecutivas, o treinamento era interrompido automaticamente e os melhores pesos eram restaurados.

Ao final do treinamento, o desempenho do modelo foi avaliado no conjunto de teste por meio das métricas de acurácia, precisão, sensibilidade (*recall*), especificidade, F1-score e área sob a curva ROC (AUC).

IV. RESULTADOS E DISCUSSÃO

Os resultados demonstram que o modelo apresentou bom desempenho na tarefa de classificação. A acurácia de 82,33% indica que mais de quatro quintos das imagens foram classificadas corretamente. Entretanto, em aplicações médicas, métricas como sensibilidade e especificidade são mais relevantes para avaliar a utilidade prática do sistema.

A precisão de 88,25% indica que, quando o modelo classificou uma imagem como metastática, essa decisão estava correta na maior parte dos casos. Esse resultado evidencia uma baixa taxa de falsos positivos, reduzindo a ocorrência de alarmes incorretos que poderiam levar à realização de exames complementares desnecessários.




Figura 2: Matriz de confusão obtida no conjunto de teste.

A Figura 2 apresenta a matriz de confusão obtida no conjunto de teste. Observa-se que o modelo produziu 149 falsos positivos e 381 falsos negativos. Em aplicações médicas, os falsos negativos representam o erro mais crítico, pois correspondem a casos em que a presença de metástase não é identificada pelo sistema.

A especificidade de 90,07% reforça essa observação, demonstrando que o modelo possui elevada capacidade de identificar corretamente tecidos saudáveis. Apenas uma pequena parcela das amostras negativas foi classificada incorretamente como positiva. Por outro lado, a sensibilidade obtida foi de 74,60%, indicando que aproximadamente três quartos das imagens contendo metástases foram corretamente detectadas.

A curva ROC apresentou área sob a curva (AUC) igual a 0,9062, indicando excelente capacidade de discriminação entre as classes. A Figura 3 demonstra que o modelo consegue




Figura 3: Curva ROC obtida no conjunto de teste.

separar adequadamente imagens saudáveis de imagens metastáticas, apresentando desempenho significativamente superior ao de um classificador aleatório.




Figura 4: Exemplos de imagens das classes negativa (tecido saudável) e positiva (metástase) do conjunto PatchCamelyon.

A Figura 4 apresenta exemplos das imagens pertencentes às classes negativa e positiva do conjunto PCam, evidenciando diferenças morfológicas entre tecidos saudáveis e regiões contendo metástases.

De modo geral, os resultados mostram que a utilização de uma ResNet18 pré-treinada como extratora de características, combinada a uma rede neural totalmente conectada para classificação, constitui uma estratégia eficiente para a detecção de metástases em imagens histopatológicas. Além de alcançar elevada capacidade discriminativa, a abordagem reduz significativamente o custo computacional em comparação ao treinamento completo de uma rede convolucional profunda.

V. CONCLUSÃO

Este trabalho apresentou uma abordagem baseada em aprendizado profundo para a detecção automática de metástases em imagens histopatológicas utilizando *Transfer Learning* com a arquitetura ResNet18. A estratégia adotada consistiu no uso da rede pré-treinada como extratora de características, combinada a uma rede neural totalmente conectada responsável pela classificação das imagens em tecidos saudáveis ou metastáticos.

Os experimentos foram conduzidos utilizando uma amostra balanceada do conjunto de dados PatchCamelyon, composta por 18.000 imagens divididas em conjuntos de treinamento, validação e teste. Os resultados obtidos demonstraram que a abordagem proposta foi capaz de alcançar acurácia de 82,33%, precisão de 88,25%, especificidade de 90,07%, F1-score de 80,85% e AUC de 0,9062. A elevada área sob a curva ROC evidencia a capacidade do modelo em distinguir adequadamente imagens contendo metástases daquelas sem alterações patológicas.

Embora o modelo tenha apresentado desempenho satisfatório, observou-se a ocorrência de falsos negativos, refletida na sensibilidade de 74,60%. Em aplicações médicas, esse tipo de erro merece atenção especial, pois representa casos em que a presença de metástase não é identificada pelo sistema.

Os resultados obtidos corroboram estudos recentes que apontam o potencial das redes neurais convolucionais como ferramentas de apoio ao diagnóstico médico, contribuindo para a redução da subjetividade inerente à análise humana e auxiliando especialistas na interpretação de imagens histopatológicas [8].

De forma geral, a utilização de redes neurais convolucionais pré-treinadas mostrou-se uma alternativa eficiente para a análise histopatológica, reduzindo custos computacionais e apresentando elevado potencial para aplicações de apoio ao diagnóstico.

Como trabalhos futuros, sugere-se a realização de experimentos com arquiteturas mais profundas, técnicas de ajuste fino (*fine-tuning*), aumento de dados (*data augmentation*) e avaliação em conjuntos de dados maiores e mais diversificados, visando aprimorar ainda mais a capacidade diagnóstica do sistema.

Declaração de Uso de Inteligência Artificial

Durante a preparação deste trabalho, os autores utilizaram ferramentas de Inteligência Artificial generativa como apoio à redação e organização do manuscrito. Foi utilizado o ChatGPT (OpenAI, GPT-5.5) para auxiliar na revisão textual, organização do manuscrito e sugestões de estrutura científica. Também foi utilizado o Claude (Anthropic, Opus 4.8) no refinamento da escrita e no apoio a decisões relacionadas à arquitetura do modelo.

Após a utilização dessas ferramentas, os autores revisaram, validaram e editaram todo o conteúdo produzido, assumindo integral responsabilidade pela implementação do modelo, pelos experimentos realizados, pela análise dos resultados e pelo conteúdo final desta publicação.

REFERÊNCIAS

- [1] G. R. G. Pessanha and E. Campos, “Um modelo de inteligência artificial para detecção de melanoma via redes neurais convolucionais,” in *Anais da 8ª Escola Regional de Computação Aplicada à Saúde (ERCAS)*. São Paulo, SP, Brasil: Sociedade Brasileira de Computação, 2021, pp. 46–49.
- [2] E. d. L. Chaves, “Detecção de câncer de mama por meio de imagens infravermelhas utilizando redes neurais convolucionais,” Uberlândia, MG, Brasil, p. 46, 2019.
- [3] W. Meohas *et al.*, “Metástase óssea: revisão da literatura,” *Revista Brasileira de Cancerologia*, vol. 51, no. 1, pp. 43–47, 2005.
- [4] A. Rajesh, D. S. Gurusamy, and R. Manickam, “Evaluating the tumor burden, histological changes, and immune landscape of breast cancer post-neoadjuvant chemotherapy: insights from 50 cases,” *Cureus*, 2024, online journal. [Online]. Available: <https://www.cureus.com>
- [5] S. M. Anwar *et al.*, “Medical image analysis using convolutional neural networks: a review,” *Journal of Medical Systems*, vol. 42, no. 11, pp. 1–13, 2018.
- [6] R. S. Santos, S. S. L. Pereira, and R. V. Costa Filho, “Avaliação de desempenho de redes neurais convolucionais para detecção de anomalias em imagens histopatológicas de câncer de mama,” Aracati, Brasil, 2024.
- [7] S. R. dos Santos Soares, “Avaliação de redes neurais convolucionais na classificação da posição do olhar em vídeos do exame cover test,” Master’s thesis, Universidade Federal do Maranhão, São Luís, MA, 2025.
- [8] A. V. Matias, “Uso de redes neurais convolucionais para detecção precoce de câncer de cavidade oral em exames de citologia convencional com coloração de papanicolau,” Master’s thesis, Universidade Federal de Santa Catarina, Florianópolis, SC, 2022.